

Nghiên cứu Mô hình Vision Transformer cho Bài toán Truy xuất Hình ảnh

Socratis Gkelios

Khoa Kỹ thuật Điện và Máy tính

Đại học Democritus, Thrace, Xanthi, Hy Lạp

sgkelios@ee.duth.gr

Yiannis Boutalis

Khoa Kỹ thuật Điện và Máy tính

Đại học Democritus, Thrace, Xanthi, Hy Lạp

ybout@ee.duth.gr

Savvas A. Chatzichristofis (*Tác giả liên hệ*)

Phòng thí nghiệm Hệ thống Thông minh, Khoa Khoa học Máy tính

Đại học Neapolis Pafos, Pafos, Cyprus

s.chatzichristofis@nup.ac.cy

Tóm tắt

Bài báo này giới thiệu một descriptor dạng plug-and-play có thể được áp dụng hiệu quả cho các bài toán truy xuất hình ảnh (image retrieval) mà không cần khởi tạo hay chuẩn bị trước. Phương pháp mô tả đặc trưng này tận dụng mạng Vision Transformer được đề xuất gần đây và không yêu cầu bất kỳ dữ liệu huấn luyện nào để điều chỉnh tham số. Trong các bài toán image retrieval, việc sử dụng các global descriptor và local descriptor thủ công (handcrafted) đã được thay thế rất thành công trong những năm gần đây bởi các phương pháp dựa trên Convolutional Neural Network (CNN). Tuy nhiên, kết quả thực nghiệm được trình bày trong bài báo này trên nhiều bộ dữ liệu benchmark, so sánh với 36 descriptor tiên tiến nhất từ các nghiên cứu trước, cho thấy rằng một mạng neural không chứa bất kỳ convolutional layer nào — như Vision Transformer — vẫn có thể tạo ra một global descriptor và đạt được kết quả cạnh tranh. Do không yêu cầu fine-tuning, độ phức tạp thấp của phương pháp này khuyến khích việc áp dụng kiến trúc này như một baseline model cho image retrieval, thay thế các cách tiếp cận CNN truyền thống và mở ra một kỷ nguyên mới trong lĩnh vực image retrieval.

I. Giới thiệu

Content-based image retrieval (CBIR) là một trong những thách thức khoa học nền tảng mà cộng đồng multimedia, computer vision và robotics đã nghiên cứu sâu rộng trong nhiều thập kỷ. Ba kỷ nguyên, khác nhau ở cách các nhà nghiên cứu trích xuất các đặc trưng định nghĩa nội dung trực quan của hình ảnh, đặc trưng cho lịch sử phát triển của CBIR [1]. Trong những năm đầu, tài liệu tập trung mạnh vào các global descriptor ở mức thấp (low-level), định hình kỷ nguyên CBIR đầu tiên. Một vector duy nhất được dùng để biểu diễn các khía cạnh khác nhau của một hình ảnh, chẳng hạn như màu sắc, hình dạng và kết cấu (texture). Tiếp theo, cộng đồng bắt đầu tập trung vào các biểu diễn dựa trên việc trích xuất và sử dụng local feature. Từ năm 2003 trở đi, các phương pháp mới áp dụng local image descriptor để tìm kiếm các image patch nổi bật và các điểm đặc trưng (points-of-interest) như cạnh (edge), góc (corner) và blob. Từ năm 2015, nghiên cứu về image retrieval chủ yếu dựa vào các phương pháp tập trung vào Deep Learning (DL) và Convolutional Neural Network (CNN). Mặc dù các kỹ thuật DL đòi hỏi lượng dữ liệu lớn để huấn luyện, các mạng pre-trained đã được chứng minh trong nhiều nghiên cứu là đặc biệt hữu ích như các feature extractor và đạt hiệu suất retrieval cao.

Trong khi đó, trong xử lý ngôn ngữ tự nhiên (natural language processing — NLP), kiến trúc dựa trên self-attention, đặc biệt là *Transformer*, hiện đang được coi là chuẩn mực mới [2]. Transformer là một loại deep neural network chủ yếu dựa trên cơ chế self-attention [3]. Gần đây, các nhà nghiên cứu đã mở rộng transformer sang các tác vụ computer vision, lấy cảm hứng từ ảnh hưởng của Transformer trong NLP [4]–[6]. Ví dụ, các tác giả trong [7] đã huấn luyện một sequence transformer để tự hồi quy dự đoán pixel và đạt kết quả cạnh tranh với CNN trong tác vụ phân loại hình ảnh. Gần đây, các tác giả trong [8] đã cố gắng áp dụng một transformer diễn hình trực tiếp lên hình ảnh với ít điều chỉnh nhất có thể, tạo ra một mạng nhận dạng hình ảnh. Vision Transformer network (ViT) cho hiệu suất tốt hơn so với CNN truyền thống trong các tác vụ nhận dạng hình ảnh.

Bài báo này xây dựng dựa trên kiến trúc Vision Transformer để tạo ra một global descriptor cho các bài toán image retrieval. Theo quy trình mà đa số các mô hình image retrieval dựa trên deep learning áp dụng, chúng tôi loại bỏ các fully connected layer của mạng Transformer và sử dụng layer cuối cùng như một đặc trưng để mô tả nội dung trực quan của hình ảnh. Theo hiểu biết của chúng tôi, đây là nỗ lực đầu tiên đánh giá hiệu suất của transformer trong các bài toán image retrieval.

Phần còn lại của bài báo được cấu trúc như sau. Phần II trình bày ngắn gọn cách kiến trúc vision transformer hoạt động và quá trình tạo image retrieval descriptor. Phần III cung cấp đánh giá thực

nghiệm toàn diện về descriptor kèm theo thảo luận kết quả. Cuối cùng, Phần IV kết luận bài báo và thảo luận về các hướng phát triển trong tương lai.

II. ViT Descriptor

Kiến trúc Transformer lần đầu tiên được giới thiệu trong [2] cho bài toán dịch máy neural (neural machine translation), đạt hiệu suất state-of-the-art và thay thế các mô hình như Long short-term memory (LSTM) và Gated recurrent unit (GRU) trong nhiều tác vụ NLP. Kiến trúc của Transformer thường bao gồm các Transformer layer xếp chồng nhau, mỗi layer nhận đầu vào là một chuỗi vector và xuất ra một chuỗi vector mới có cùng hình dạng. Yếu tố cốt lõi của các kiến trúc Transformer nằm ở cơ chế attention. Động lực chính của sự phát triển Transformer là khắc phục các hạn chế của recurrent neural network (RNN) và chủ yếu là để nắm bắt các phụ thuộc toàn cục dài hạn (long-term global dependency). Dựa trên nền tảng này, nhiều phương pháp đáng chú ý đã xuất hiện, ví dụ như Bidirectional Encoder Representations from Transformers (BERT) [9] và GPT-3 [10], cả hai đều được pre-train theo phương thức unsupervised từ văn bản chưa được gán nhãn. Các phương pháp này thể hiện khả năng biểu diễn phong phú mà không cần fine-tuning, đồng thời đơn giản về mặt khái niệm và mạnh mẽ về mặt thực nghiệm.

Việc áp dụng Transformer vào các tác vụ computer vision đặt ra một thách thức đáng kể vì hai lý do chính:

- Hình ảnh chứa nhiều thông tin hơn nhiều so với từ hay câu văn.
- Việc tính toán attention trên từng pixel đòi hỏi chi phí tính toán rất lớn.

Các tác giả trong [8] đề xuất một phương pháp mới gọi là Vision Transformer (ViT) để giải quyết những thách thức này. ViT mượn phần encoder của NLP Transformer. Transformer chuẩn nhận đầu vào là một chuỗi token embedding 1D. Trong trường hợp này, hình ảnh được chia thành các patch có kích thước cố định và đưa vào mô hình. Một vector positional embedding có thể học được gán cho mỗi patch để tận dụng thứ tự của chuỗi đầu vào. Ngoài ra, một special token được thêm vào, tương tự như trong trường hợp của BERT. Tóm lại, một tập hợp các patch được xây dựng cho mỗi hình ảnh, nhân với một embedding matrix, sau đó kết hợp với một positional embedding vector, tạo thành đầu vào cho Transformer. Ở tất cả các layer, Transformer sử dụng kích thước latent vector cố định, vì vậy với một linear projection có thể huấn luyện được, các patch được làm phẳng (flatten) để ánh xạ sang các chiều này. Đầu ra của phép chiếu này được gọi là patch embedding.

Mỗi encoder gồm hai sub-layer. Ở sub-layer thứ nhất, đầu vào đi qua một self-attention module; ở sub-layer thứ hai, đầu ra của phép tính self-attention được truyền vào một position-wise feed-

forward neural network. Ngoài ra, skip connection [11] được tích hợp xung quanh mỗi sub-layer và áp dụng layer normalization. Kiến trúc của encoder được minh họa trong Hình 2. Mỗi layer chứa một linear projection ánh xạ cố định của các patch được làm phẳng với chiều D được tinh chỉnh trong quá trình huấn luyện. D bằng 768 với kiến trúc ViT-B, trong khi với ViT-L giá trị tương ứng là 1024. Mặc dù các encoder layer được cấu thành từ các phần tử cấu trúc giống nhau, chúng không chia sẻ trọng số.

Self-attention module gồm ba thành phần có thể học được: Query (Q), Key (K) và Value (V). Một score matrix được tạo thành bằng phép nhân dot product của Q và K, biểu diễn mức độ attention của mỗi "từ" với mỗi "từ" khác (trong phương pháp của chúng tôi, mỗi "từ" tương ứng với một image patch). Score matrix được chia tỉ lệ và đưa qua softmax layer để chuyển đổi thành xác suất. Tiếp theo, đầu ra của softmax được nhân với vector V để làm nổi bật các từ quan trọng. Multi-headed attention cải thiện hiệu suất của Transformer. Cụ thể, mô hình thực hiện nhiều hàm attention song song trên các linear projection khác nhau của các vector Q, V và K thay vì chỉ dùng một hàm duy nhất. Điều này cho phép mô hình tập trung vào các vị trí và không gian biểu diễn (representation subspace) khác nhau.

Position-wise neural network module là một fully connected feed-forward neural network (FFNN), gồm hai phép biến đổi tuyến tính với hàm kích hoạt ReLU ở giữa. Layer Layernorm (LN) được áp dụng trước mỗi module, và residual connection được sử dụng sau mỗi block, tiếp theo là layer normalization [12].

Trong bài báo này, chúng tôi áp dụng kiến trúc pre-trained của [8]. Cụ thể, bài báo sử dụng mô hình 'Base' (ViT-B) và mô hình 'Large' (ViT-L) từ BERT. Hai biến thể của mỗi kiến trúc theo kích thước patch đầu vào được áp dụng: ViT-L16 tương ứng với kích thước patch đầu vào 16×16 , trong khi ViT-L32 tương ứng với kích thước patch 32×32 . Ký hiệu tương tự được dùng cho mô hình ViT-B. Các mô hình có patch nhỏ hơn đòi hỏi nhiều tài nguyên tính toán hơn do mối quan hệ tỉ lệ nghịch giữa độ dài chuỗi của Transformer và bình phương kích thước patch.

Các kiến trúc được áp dụng đã được huấn luyện trên 21k-ImageNet (21.000 lớp / 14 triệu hình ảnh) và được fine-tune trên ILSVRC-2012 ImageNet (1.000 lớp / 1,3 triệu hình ảnh) [13]. ViT-B có 12 encoder layer với FFNN kích thước 3072. Trong khi đó, ViT-L có 24 encoder layer với FFNN kích thước 4096.

Với ViT descriptor, ban đầu tất cả các hình ảnh được resize về kích thước 384×384 pixel. Một đơn vị tiền xử lý trừ 127,5 khỏi tất cả các pixel và chia cho 255 để đưa giá trị pixel về khoảng $[-1, 1]$. Các hình ảnh đã qua tiền xử lý được đưa qua Transformer Encoder. Layer softmax cuối cùng của các mô hình được loại bỏ, để lại đầu ra đã chuẩn hóa của encoder cuối cùng với chiều D làm layer cuối cùng. Quy trình này tạo ra một vector biểu diễn cho mỗi hình ảnh. Bước cuối cùng bao gồm một thủ tục chuẩn hóa để tạo ra ViT descriptor. Hình 1 minh họa kiến trúc CBIR được đề xuất.

III. Thiết lập Thực nghiệm

Phần này cung cấp chi tiết về các thực nghiệm được thực hiện để đánh giá ViT descriptor. Biểu diễn hình ảnh được đề xuất được đánh giá trên bốn bộ dữ liệu hình ảnh nổi tiếng:

- **INRIA Holidays [14]:** Bộ dữ liệu gồm 1.491 ảnh chụp từ điện thoại di động với nhiều cảnh kỳ nghỉ và đối tượng đa dạng. Số lượng hình ảnh mỗi nhóm dao động từ 2 đến 13. INRIA Holidays cung cấp nhiều query image thay vì UKBench. Ground truth bao gồm các hình ảnh có nội dung trực quan giống với query image, mà không chỉ ra sự xuất hiện của cùng một đối tượng.
- **UKBench [15]:** Bộ dữ liệu gồm 10.200 hình ảnh được sắp xếp trong 2.250 danh mục. Mỗi danh mục có bốn ảnh chụp một đối tượng từ các góc độ khác nhau và trong các điều kiện ánh sáng khác nhau. Điểm số top-4 candidate (NS) [15] được sử dụng để tính độ chính xác retrieval trên bộ dữ liệu này.
- **Paris6K [16]:** Bộ dữ liệu gồm 6.412 bức ảnh đại diện cho các địa danh nổi tiếng tại Paris. Bộ sưu tập bao gồm 55 ảnh về các tòa nhà và công trình từ các yêu cầu truy vấn. Paris6K có sự đa dạng hơn về địa danh so với Oxford5K.
- **Oxford5K [17]:** Bộ dữ liệu về các tòa nhà gồm 5.062 ảnh từ Flickr. Bộ dữ liệu được gán nhãn thủ công để tạo ground truth chi tiết cho 11 địa danh riêng biệt, mỗi địa danh được đại diện bởi năm potential query. Tổng cộng, index gồm 55 yêu cầu. Trong bộ dữ liệu này, các góc nhìn hoàn toàn khác nhau của cùng một tòa nhà được gán cùng tên, khiến bộ dữ liệu trở nên thách thức hơn cho image retrieval [18].

Với các bộ dữ liệu INRIA, Oxford5K và Paris6K, mean Average Precision (mAP) [19] được sử dụng làm metric đánh giá. Trong trường hợp retrieval hoàn hảo, mAP bằng 100; khi số lượng hình ảnh không liên quan được xếp hạng cao hơn một hình ảnh liên quan tăng lên, mAP tiến về 0. Trong khi đó, hiệu suất retrieval trên UKBench được đánh giá bằng tỷ lệ recall cho top-4 candidate (NS). Trong trường hợp retrieval hoàn hảo, NS bằng 4.

Để tính độ tương đồng giữa các descriptor, chúng tôi sử dụng nhiều distance metric. Mỗi similarity metric có những ưu điểm và nhược điểm riêng, phù hợp hơn với từng loại dữ liệu nhất định [20]. Bài báo này đánh giá việc sử dụng các distance metric Manhattan, Euclidean, Cosine, Bray-Curtis, Canberra, Chebyshev và Correlation. Hai metric Manhattan và Euclidean là các metric phổ biến nên không trình bày chi tiết thêm. Ở đây chỉ lưu ý rằng Manhattan Distance (còn gọi là city block distance) được ưu tiên hơn Euclidean khi chiều dữ liệu tăng cao.

Cosine distance đo lường không gian tích vô hướng (inner-product space) của các image descriptor, xét đến hướng chứ không phải độ lớn:

$$d_{Cosine}(\mathbf{p}, \mathbf{q}) = \frac{pq}{\|\mathbf{p}\|\|\mathbf{q}\|} = \frac{\sum_{i=1}^n p_i q_i}{\sqrt{\sum_{i=1}^n (p_i)^2} \sqrt{\sum_{i=1}^n (q_i)^2}} \quad (1)$$

Bray-Curtis và Canberra được biến thể từ Manhattan, trong đó tổng hiệu giữa các tọa độ của vector được chuẩn hóa:

$$d_{Canberra}(\mathbf{p}, \mathbf{q}) = \sum_{i=1}^n \frac{|p_i - q_i|}{|p_i| + |q_i|} \quad (2)$$

$$d_{Bray-Curtis}(\mathbf{p}, \mathbf{q}) = \frac{\sum_{i=1}^n |p_i - q_i|}{\sum_{i=1}^n (p_i + q_i)} \quad (3)$$

Chebyshev distance giữa hai feature vector được ước tính là biến thiên lớn nhất theo bất kỳ chiều tọa độ nào:

$$d_{Chebyshev}(\mathbf{p}, \mathbf{q}) = \max_i (|p_i - q_i|) \quad (4)$$

Cuối cùng, Correlation distance đo lường sự phụ thuộc giữa hai feature vector:

$$d_{Correl.}(\mathbf{p}, \mathbf{q}) = \frac{\sum_{i=1}^n (p_i - \bar{p})(q_i - \bar{q})}{\sqrt{\sum_{i=1}^n (p_i - \bar{p})^2} \sqrt{\sum_{i=1}^n (q_i - \bar{q})^2}} \quad (5)$$

Trong tất cả các metric, $\mathbf{p}$ và $\mathbf{q}$ là các image descriptor tương ứng.

Ngoài ra, phần này cũng đánh giá kỹ thuật normalization phù hợp. Kỹ thuật batch normalization thúc đẩy quá trình huấn luyện bằng cách chuẩn hóa đầu vào của mỗi layer về mean bằng 0 và variance bằng 1. Weight normalization tái tham số hóa các weight vector trong một mạng neural, tách biệt độ dài của các weight vector khỏi hướng của chúng [21], lấy cảm hứng từ batch normalization. Nói cách khác, weight normalization tái tham số hóa các trọng số đầu vào theo L2-norm hoặc L1-norm [22].

L1-norm sử dụng tổng tất cả các giá trị, áp đặt penalty bằng nhau cho tất cả tham số, thúc đẩy tính thưa thớt (sparsity):

$$X'_i = \frac{X_i}{\sum_{k=0}^n X_k} \quad (6)$$

Tương tự, L2-norm sử dụng căn bậc hai của tổng bình phương tất cả các giá trị:

$$X'_i = \frac{X_i}{\sum_{k=0}^n X_k^2} \quad (7)$$

Trong tất cả các trường hợp, X_i là giá trị cần chuẩn hóa và X'_i là giá trị đã chuẩn hóa.

Phương pháp post-processing normalization gồm: chuẩn hóa độc lập từng descriptor (L1-norm và L2-norm Axis-1), chuẩn hóa từng đặc trưng (L1-norm và L2-norm Axis-0), và scaling kiểu *ROBUST*:

$$X'_i = \frac{X_i - q_1(X_i)}{q_2(X_i) - q_1(X_i)} \tag{8}$$

trong đó q_1 và q_2 là các quantile.

Scaling normalization kiểu *ROBUST* loại bỏ ảnh hưởng của median và điều chỉnh dữ liệu theo khoảng quantile, nghĩa là mean mẫu và variance không bị ảnh hưởng bởi các outlier.

A. Kết quả Retrieval

Bảng I, II, III và IV liệt kê hiệu suất image retrieval trên các bộ dữ liệu INRIA, UKBench, Paris6K và Oxford5K. Kết luận đầu tiên rút ra được là ViT descriptor hoạt động tốt đáng kể với hầu hết các similarity metric và tất cả các kỹ thuật normalization trên cả bốn bộ dữ liệu. Trong tất cả các thực nghiệm, Chebyshev metric tụt hậu đáng kể so với các distance metric còn lại.

Bảng I — Kết quả thực nghiệm trên bộ dữ liệu INRIA

Model	Manh.	Eucl.	Cos	BC	Canb.	Cheb.	Correl.
ViT-L16							
L2 Axis=1	84.95	84.98	84.98	84.88	84.62	76.24	84.97
L2 Axis=0	85.02	85.24	85.36	85.07	84.54	77.67	85.36
L1 Axis=1	84.77	84.88	84.98	84.91	84.67	76.26	84.97
L1 Axis=0	85.02	85.23	85.53	85.08	84.54	78.02	85.52
ROBUST	84.98	85.10	86.31	86.08	85.50	76.71	86.31
ViT-L32							
L2 Axis=1	86.84	86.56	86.56	86.77	86.32	75.90	86.56
L2 Axis=0	86.65	86.61	86.96	86.92	86.30	76.34	86.96
L1 Axis=1	86.88	86.57	86.56	86.78	86.32	75.45	86.56
L1 Axis=0	86.65	86.64	86.97	86.92	86.30	76.52	86.97
ROBUST	86.61	86.61	87.03	87.05	86.80	76.83	87.03

Model	Manh.	Eucl.	Cos	BC	Canb.	Cheb.	Correl.
ViT-B16							
L2 Axis=1	87.16	87.09	87.09	87.17	86.57	75.77	87.09
L2 Axis=0	86.79	86.53	86.76	87.26	86.55	77.95	87.67
L1 Axis=1	87.18	86.97	87.09	87.18	86.58	75.30	87.09
L1 Axis=0	86.78	86.51	87.67	87.29	86.55	77.31	87.67
ROBUST	86.42	86.33	87.99	87.81	87.32	77.07	87.99
ViT-B32							
L2 Axis=1	85.07	84.80	84.80	85.19	84.61	62.52	84.80
L2 Axis=0	84.97	85.04	85.61	85.38	84.74	77.96	85.61
L1 Axis=1	85.31	84.96	84.80	85.19	84.76	61.84	84.80
L1 Axis=0	84.98	84.93	85.63	85.38	84.74	77.25	85.63
ROBUST	84.96	85.07	86.11	86.22	85.32	76.85	86.11

Bảng II — Kết quả thực nghiệm trên bộ dữ liệu UKBench

Model	Manh.	Eucl.	Cos	BC	Canb.	Cheb.	Correl.
ViT-L16							
L2 Axis=1	3.782	3.785	3.785	3.781	3.764	3.561	3.785
L2 Axis=0	3.778	3.780	3.785	3.782	3.764	3.575	3.785
L1 Axis=1	3.781	3.783	3.785	3.781	3.764	3.560	3.785
L1 Axis=0	3.778	3.781	3.785	3.782	3.764	3.574	3.785
ROBUST	3.777	3.779	3.784	3.781	3.763	3.567	3.784
ViT-L32							
L2 Axis=1	3.750	3.752	3.752	3.750	3.730	3.416	3.752
L2 Axis=0	3.735	3.737	3.754	3.751	3.731	3.455	3.754

Model	Manh.	Eucl.	Cos	BC	Canb.	Cheb.	Correl.
L1 Axis=1	3.752	3.751	3.752	3.750	3.731	3.412	3.752
L1 Axis=0	3.735	3.737	3.754	3.751	3.731	3.453	3.754
ROBUST	3.735	3.737	3.749	3.747	3.729	3.455	3.749
ViT-B16							
L2 Axis=1	3.745	3.746	3.746	3.745	3.728	3.345	3.746
L2 Axis=0	3.733	3.737	3.758	3.752	3.729	3.496	3.758
L1 Axis=1	3.746	3.746	3.746	3.746	3.729	3.340	3.746
L1 Axis=0	3.733	3.737	3.758	3.752	3.729	3.496	3.758
ROBUST	3.733	3.737	3.759	3.752	3.733	3.496	3.759
ViT-B32							
L2 Axis=1	3.712	3.702	3.702	3.712	3.692	2.971	3.702
L2 Axis=0	3.709	3.714	3.725	3.718	3.693	3.442	3.725
L1 Axis=1	3.711	3.701	3.702	3.712	3.693	2.952	3.702
L1 Axis=0	3.709	3.714	3.725	3.717	3.693	3.439	3.725
ROBUST	3.709	3.714	3.726	3.722	3.697	3.450	3.726

Phân tích sâu hơn về kết quả cũng cho thấy ViT-B16 descriptor hoạt động ổn định tốt trên tất cả các bộ dữ liệu. Tất nhiên, trong bộ dữ liệu UKBench, ViT-L16 descriptor vượt nhẹ ViT-B16, nhưng sự khác biệt không đủ đáng kể để rút ra kết luận tổng quát. ViT-B16 descriptor thể hiện độ chính xác retrieval cao, thúc đẩy tính ổn định trên tất cả các bộ dữ liệu và hầu hết các similarity metric.

Về các kỹ thuật normalization, ROBUST scaling có vẻ là lựa chọn tối ưu. Hơn nữa, có thể nhanh chóng kết luận rằng kết hợp ROBUST normalization với Cosine distance làm similarity metric tạo ra cấu hình hiệu quả nhất cho descriptor. Sự kết hợp này vượt trội hơn bất kỳ thiết kế nào khác trong tất cả các thực nghiệm được thực hiện. Do đó, có thể kết luận rằng tổ hợp mô hình ViT-B16 với ROBUST normalization và Cosine distance làm similarity metric tạo thành một giải pháp plug-and-play ổn định và hiệu quả cho image retrieval.

Bảng III — Kết quả thực nghiệm trên bộ dữ liệu Paris6K

Model	Manh.	Eucl.	Cos	BC	Canb.	Cheb.	Correl.
ViT-L16							
L2 Axis=1	86.24	86.23	86.23	86.25	85.82	77.34	86.25
L2 Axis=0	86.27	86.24	86.63	86.46	85.82	76.16	86.63
L1 Axis=1	86.17	86.15	86.23	86.25	85.82	77.17	86.25
L1 Axis=0	86.25	86.23	86.64	86.47	85.82	75.97	86.64
ROBUST	86.18	86.13	86.74	86.71	86.38	76.16	86.74
ViT-L32							
L2 Axis=1	85.29	85.34	85.34	85.41	85.09	72.56	85.34
L2 Axis=0	84.48	84.47	85.68	85.65	85.11	69.76	85.68
L1 Axis=1	85.37	85.42	85.34	85.41	85.10	72.60	85.34
L1 Axis=0	84.45	84.45	85.69	85.65	85.11	69.57	85.69
ROBUST	84.40	84.35	85.62	85.61	85.18	69.04	85.62
ViT-B16							
L2 Axis=1	86.94	87.07	87.07	86.85	86.25	75.96	87.07
L2 Axis=0	86.28	86.23	87.21	86.97	86.27	77.26	87.21
L1 Axis=1	86.93	87.06	87.07	86.84	86.25	75.72	87.07
L1 Axis=0	86.27	86.20	87.23	86.99	86.27	77.06	87.23
ROBUST	86.43	86.46	87.83	87.63	87.06	76.61	87.83
ViT-B32							
L2 Axis=1	85.53	85.29	85.29	85.56	85.24	64.04	85.28
L2 Axis=0	85.34	85.29	85.95	85.83	85.23	75.96	85.94
L1 Axis=1	85.50	85.19	85.29	85.56	85.23	63.55	85.28
L1 Axis=0	85.34	85.27	85.96	85.83	85.23	75.77	85.96
ROBUST	85.29	85.24	86.32	86.35	85.90	75.51	86.32

Bảng IV — Kết quả thực nghiệm trên bộ dữ liệu Oxford5K

Model	Manh.	Eucl.	Cos	BC	Canb.	Cheb.	Correl.
ViT-L16							
L2 Axis=1	60.84	60.82	60.82	60.78	59.87	51.49	60.83
L2 Axis=0	60.90	61.20	61.50	61.15	59.85	53.26	61.50
L1 Axis=1	60.73	60.74	60.82	60.78	59.85	51.21	60.83
L1 Axis=0	60.91	61.13	61.58	61.20	59.85	53.12	61.58
ROBUST	60.82	60.86	62.37	62.09	61.49	52.45	62.37
ViT-L32							
L2 Axis=1	55.17	55.30	55.30	55.01	53.84	41.26	55.28
L2 Axis=0	54.92	55.14	55.55	55.21	53.84	41.45	55.55
L1 Axis=1	55.35	55.43	55.30	55.01	53.86	41.39	55.28
L1 Axis=0	54.93	55.18	55.56	55.23	53.84	41.31	55.56
ROBUST	54.93	55.19	56.30	55.88	55.16	41.78	56.30
ViT-B16							
L2 Axis=1	63.24	63.59	63.59	63.22	62.17	52.44	63.59
L2 Axis=0	62.74	63.16	64.19	63.53	62.12	56.79	64.19
L1 Axis=1	63.13	63.68	63.59	63.26	62.13	52.30	63.59
L1 Axis=0	62.79	63.14	64.22	63.55	62.12	56.48	64.22
ROBUST	62.72	63.05	64.68	64.09	62.84	56.02	64.68
ViT-B32							
L2 Axis=1	63.18	62.49	62.49	63.08	62.84	41.78	62.49
L2 Axis=0	63.34	63.01	63.56	63.52	62.82	53.96	63.56
L1 Axis=1	63.19	62.41	62.49	63.10	62.80	41.33	62.49
L1 Axis=0	63.35	62.99	63.59	63.54	62.82	53.78	63.59

Model	Manh.	Eucl.	Cos	BC	Canb.	Cheb.	Correl.
ROBUST	63.35	63.09	64.43	64.28	63.35	53.99	64.43

B. So sánh với các Phương pháp State-of-the-art

Phần này so sánh hiệu suất của ViT descriptor với các phương pháp local, global và deep convolutional-based tiên tiến nhất từ các nghiên cứu gần đây. Descriptor được đề xuất được so sánh với 36 descriptor từ tài liệu. Các descriptor được chọn chủ yếu dựa trên hiệu suất được báo cáo và mức độ phổ biến tổng thể. Các descriptor được liệt kê trong Bảng V và sắp xếp theo hiệu suất retrieval trên bộ dữ liệu INRIA.

Kết quả thực nghiệm cho thấy ViT descriptor hoạt động ổn định và đạt kết quả đáng kể trên tất cả các bộ dữ liệu benchmark. Kết quả trong Bảng V chứng minh rằng phương pháp được đề xuất hoạt động tương đương với các phương pháp state-of-the-art trên tất cả các bộ dữ liệu. Hơn nữa, kết quả retrieval đạt được nằm trong nhóm dẫn đầu và có thể so sánh trực tiếp với kết quả tốt nhất được báo cáo trong tài liệu.

Bảng V — Điểm retrieval trên từng bộ dữ liệu

(*mAP* cho *INRIA*, *Paris6K*, *Oxford5K*; *điểm N-S* cho *UKBen**ch*. † chỉ kết quả được báo cáo trong [23], [24])

Phương pháp Retrieval	INRIA	UKBen.	Paris	Oxford
MMF-HC [25]	94.1	3.87	—	—
MR Spatial search [26]	89.6	—	87.9	84.3
GatedSQU [23]	88.8	3.74	81.3	69.4
ViT-B16 (đề xuất)	88.0	3.76	87.8	64.7
ASMK+SA (large) [27]	88.0	—	78.7	82.0
ASMK+MA (large) [27]	86.5	—	80.5	83.8
Zheng et al. (PPS) [28]	85.2	3.79	—	—
R-mac [29]	85.2†	3.74†	83.0	66.9
R-mac-RPN [24]	86.7	—	87.1	83.1
CroW [30]	85.1	3.63†	79.7	70.8

Phương pháp Retrieval	INRIA	UKBen.	Paris	Oxford
MMF-SIFT [25]	84.4	3.94	—	—
CNNaug-ss [31]	84.3	—	46.0	36.0
SMK+SA (large) [27]	84.0	—	73.2	78.5
HE+WGC [32]	81.3	3.42	61.5	51.6
GoogleNet [31]	83.6	—	58.3	55.8
ReDSL.FC1 [33]	—	—	94.7	78.3
R101-DELG [34]	—	—	82.9	78.5
Varga et al. [35]	—	—	—	74.4
SMK+MA (large) [27]	82.9	—	74.2	79.3
CVLAD [36]	82.7	3.62	—	51.4
OxfordNet [31]	81.6	—	59.0	59.3
Local CoMo [37]	81.1	—	—	—
CNN+BoVW [38]	80.2	—	—	—
MOP-CNN [39]	80.2	—	—	—
Patch-CKN [40]	79.3	3.76	—	56.5
Neural codes [41]	79.3	3.29	—	54.5
Alexnet-conv3 [42]	79.3	3.76	—	43.4
LBOW [15]	78.9	3.50	—	—
Alexnet-conv4 [42]	77.1	3.73	—	34.3
SaCoCo [43]	76.1	3.33	—	—
Alexnet-conv5 [42]	75.3	3.69	—	47.7
PhilippNet [44]	74.1	3.66	—	—
CEDD [45]	72.6	3.06	—	—
CoMo [37]	72.6	—	—	—

Phương pháp Retrieval	INRIA	UKBen.	Paris	Oxford
Alexnet-conv2 [42]	62.7	3.19	—	12.5
Alexnet-conv1 [42]	59.0	3.33	—	18.8
BoVW [15]	57.2	2.95	—	—

Trên bộ dữ liệu INRIA và UKBench, giải pháp được đề xuất đạt kết quả tốt thứ tư được báo cáo. Với Paris6K, ViT descriptor đạt hiệu suất tốt thứ ba. Với Oxford5K, hiệu quả của ViT descriptor tương đương với các phương pháp image retrieval dựa trên CNN. Đáng chú ý là toàn bộ hình ảnh được sử dụng làm query trên cả Oxford5K và Paris6K thay vì chỉ vùng quan tâm (region of interest) đã được chú thích.

Tóm lại, ViT descriptor vượt trội đáng kể so với tất cả các đặc trưng handcrafted và hầu hết các phương pháp CNN-based trong tất cả các bộ dữ liệu. Tất nhiên, tài liệu còn chứa nhiều phương pháp và thuật toán tinh vi hơn vượt qua độ chính xác retrieval của descriptor này. Nhưng một lần nữa cần nhấn mạnh rằng ViT descriptor là một giải pháp plug-and-play, sẵn sàng sử dụng ngay, không cần huấn luyện hay điều chỉnh tham số. Phần lớn các phương pháp deep learning được liệt kê đều phức tạp và đòi hỏi nhiều hơn đáng kể so với giải pháp ViT.

Ví dụ, trong [25], một sơ đồ multi-index fusion cho image retrieval được đề xuất dựa trên mạng AlexNet và ResNet50. Phương pháp này gọi là MMF và kế thừa ý tưởng cốt lõi của Collaborative Index Embedding để kết hợp các biểu diễn trực quan khác nhau ở cấp độ index. Hơn nữa, MMF khám phá thông tin bậc cao bằng cách xem xét cấu trúc index thưa thớt (sparse index structure) cho retrieval — một thuộc tính nội tại của cấu trúc inverted index. Hiệu suất ấn tượng được báo cáo bởi [25] đòi hỏi việc tạo và học một functional matrix đặc thù cho index để lan truyền độ tương đồng và áp dụng Augmented Lagrange Multiplier (ALM) để tối ưu hóa multi-index fusion. Bằng cách tính đến nhiều yếu tố như bất biến hình học (geometric invariance), số lớp và hiệu quả tìm kiếm, một kiến trúc CNN được tối ưu hóa đã được tạo ra và huấn luyện, được gọi là MR Spatial search [26]. Điểm quan trọng là MR Spatial search thực hiện spatial verification tốn kém tại thời điểm kiểm tra. Các tác giả trong [23] tập trung vào global feature pooling trên CNN activation cho image instance retrieval. Descriptor được gọi là GatedSQU, bao gồm thiết kế channel-wise pooling và học với triplet loss. Các tác giả trong [35] kết hợp độ tương đồng ở mức ngữ nghĩa (semantic-level similarity) và mức đặc trưng (feature-level similarity) để tính khoảng cách tương đồng hiệu quả. Các tác giả trong [33] thực hiện một loạt nghiên cứu phân tích toàn diện nhằm hình thành các biểu diễn đặc trưng hiệu quả hơn. Cuối cùng, đáng chú ý rằng phương pháp ReDSL.FC1 vượt trội đáng kể so với tất cả các phương pháp được báo cáo trên bộ dữ liệu Paris và Oxford vì các tác giả đã fine-tune kiến trúc CNN pre-trained trực tiếp trên các địa danh này bằng similarity learning.

Các thực nghiệm được thực hiện trên một máy trạm với CPU AMD Ryzen 7 1700, 32GB RAM và GPU GTX 1080, sử dụng framework KERAS [46] — một thư viện neural network Python cấp cao nổi tiếng chạy trên nền TensorFlow hoặc Theano. Triển khai Vision Transformer dựa trên bản phát hành mã nguồn mở của mạng có trên GitHub: <https://github.com/faustomoraes/vit-keras>

IV. Kết luận

Bài báo này trình bày một image retrieval descriptor hoàn toàn unsupervised và không cần tham số. Nhìn chung, giải pháp được đề xuất có vẻ phù hợp cho các tác vụ content-based image retrieval. Kết quả đánh giá thực nghiệm trên nhiều bộ dữ liệu khác nhau đã chứng minh rõ ràng rằng phương pháp được đề xuất vượt trội so với nhiều giải pháp phức tạp và tinh vi hơn từ tài liệu. Mặc dù ViT descriptor không vượt qua tất cả các phương pháp khác, có thể kết luận rằng nó mang lại một hướng tiếp cận mới cho lĩnh vực image retrieval. Một hướng quan trọng để cải thiện hiệu suất image retrieval là xem xét lại các phương pháp CNN-based đã được thiết lập tốt trong tài liệu và thay thế backbone pre-trained network bằng vision transformer. Một chương mới trong lĩnh vực khoa học image retrieval đang hình thành.

Tài liệu tham khảo

- [1] L. Zheng, Y. Yang, và Q. Tian, "Sift meets cnn: A decade survey of instance retrieval," *IEEE transactions on pattern analysis and machine intelligence*, vol. 40, no. 5, pp. 1224–1244, 2018.
- [2] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, và I. Polosukhin, "Attention is all you need," *Advances in neural information processing systems*, vol. 30, pp. 5998–6008, 2017.
- [3] X. Wang, R. Girshick, A. Gupta, và K. He, "Non-local neural networks," trong *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 7794–7803.
- [4] K. Han, Y. Wang, H. Chen, X. Chen, J. Guo, Z. Liu, Y. Tang, A. Xiao, C. Xu, Y. Xu et al., "A survey on visual transformer," *arXiv preprint arXiv:2012.12556*, 2020.
- [5] F. Locatello, D. Weissenborn, T. Unterthiner, A. Mahendran, G. Heigold, J. Uszkoreit, A. Dosovitskiy, và T. Kipf, "Object-centric learning with slot attention," *arXiv preprint arXiv:2006.15055*, 2020.

- [6] H. Hu, J. Gu, Z. Zhang, J. Dai, và Y. Wei, "Relation networks for object detection," trong *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018, pp. 3588–3597.
- [7] M. Chen, A. Radford, R. Child, J. Wu, H. Jun, D. Luan, và I. Sutskever, "Generative pretraining from pixels," trong *International Conference on Machine Learning*. PMLR, 2020, pp. 1691–1703.
- [8] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly et al., "An image is worth 16x16 words: Transformers for image recognition at scale," *arXiv preprint arXiv:2010.11929*, 2020.
- [9] J. Devlin, M.-W. Chang, K. Lee, và K. Toutanova, "Bert: Pre-training of deep bidirectional transformers for language understanding," *arXiv preprint arXiv:1810.04805*, 2018.
- [10] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, và D. Amodei, "Language models are few-shot learners," 2020.
- [11] Q. Wang, B. Li, T. Xiao, J. Zhu, C. Li, D. Wong, và L. Chao, "Learning deep transformer models for machine translation," 01 2019, pp. 1810–1822.
- [12] J. L. Ba, J. R. Kiros, và G. E. Hinton, "Layer normalization," *arXiv preprint arXiv:1607.06450*, 2016.
- [13] J. Deng, W. Dong, R. Socher, L. Li, Kai Li, và Li Fei-Fei, "Imagenet: A large-scale hierarchical image database," trong *2009 IEEE Conference on Computer Vision and Pattern Recognition*, 2009, pp. 248–255.
- [14] H. Jegou, M. Douze, và C. Schmid, "Hamming embedding and weak geometric consistency for large scale image search," trong *Computer Vision – ECCV 2008*. Berlin, Heidelberg: Springer, 2008, pp. 304–317.
- [15] C. Wengert, M. Douze, và H. Jegou, "Bag-of-colors for improved image search," trong *Proceedings of the 19th ACM International Conference on Multimedia*, MM '11. New York, NY, USA: ACM, 2011, pp. 1437–1440.
- [16] J. Philbin, O. Chum, M. Isard, J. Sivic, và A. Zisserman, "Lost in quantization: Improving particular object retrieval in large scale image databases," trong *CVPR 2008*. IEEE, 2008, pp. 1–8.

- [17] — —, "Object retrieval with large vocabularies and fast spatial matching," trong *2007 IEEE conference on computer vision and pattern recognition*. IEEE, 2007, pp. 1–8.
- [18] V. R. Chandrasekhar, D. M. Chen, S. S. Tsai, N.-M. Cheung, H. Chen, G. Takacs, Y. Reznik, R. Vedantham, R. Grzeszczuk, J. Bach et al., "The stanford mobile visual search data set," trong *Proceedings of the second annual ACM conference on Multimedia systems*, 2011, pp. 117–122.
- [19] S. Chatzichristofis, C. Iakovidou, Y. Boutalis, và E. Angelopoulou, "Mean normalized retrieval order (mnro): a new content-based image retrieval performance measure," *Multimedia Tools and Applications*, pp. 1–32, 2012.
- [20] S. Patil và S. Talbar, "Content based image retrieval using various distance metrics," trong *Data Engineering and Management*. Berlin, Heidelberg: Springer, 2012, pp. 154–161.
- [21] T. Salimans và D. P. Kingma, "Weight normalization: A simple reparameterization to accelerate training of deep neural networks," trong *Advances in neural information processing systems*, 2016, pp. 901–909.
- [22] S. Wu, G. Li, L. Deng, L. Liu, D. Wu, Y. Xie, và L. Shi, "l1-norm batch normalization for efficient training of deep neural networks," *IEEE transactions on neural networks and learning systems*, vol. 30, no. 7, pp. 2043–2051, 2018.
- [23] Z. Chen, J. Lin, V. Chandrasekhar, và L.-Y. Duan, "Gated square-root pooling for image instance retrieval," trong *2018 25th IEEE International Conference on Image Processing (ICIP)*. IEEE, 2018, pp. 1982–1986.
- [24] A. Gordo, J. Almazan, J. Revaud, và D. Larlus, "Deep image retrieval: Learning global representations for image search," trong *European conference on computer vision*. Springer, 2016, pp. 241–257.
- [25] Z. Zhang, Y. Xie, W. Zhang, và Q. Tian, "Effective image retrieval via multilinear multi-index fusion," *IEEE Transactions on Multimedia*, 2019.
- [26] A. S. Razavian, J. Sullivan, S. Carlsson, và A. Maki, "Visual instance retrieval with deep convolutional networks," *ITE Transactions on Media Technology and Applications*, vol. 4, no. 3, pp. 251–258, 2016.
- [27] G. Tolias, Y. S. Avrithis, và H. Jegou, "Image search with selective match kernels: Aggregation across single and multiple images," *International Journal of Computer Vision*, vol. 116, no. 3, pp. 247–261, 2016.

- [28] L. Zheng, S. Wang, và Q. Tian, "Coupled binary embedding for large-scale image retrieval," *IEEE Transactions on Image Processing*, vol. 23, no. 8, pp. 3368–3380, 2014.
- [29] G. Tolias, R. Sivic, và H. Jegou, "Particular object retrieval with integral max-pooling of cnn activations," *arXiv preprint arXiv:1511.05879*, 2015.
- [30] Y. Kalantidis, C. Mellina, và S. Osindero, "Cross-dimensional weighting for aggregated deep convolutional features," trong *European conference on computer vision*. Springer, 2016, pp. 685–701.
- [31] J. Yue-Hei Ng, F. Yang, và L. S. Davis, "Exploiting local features from deep networks for image retrieval," trong *Proceedings of the IEEE conference on computer vision and pattern recognition workshops*, 2015, pp. 53–61.
- [32] H. Jegou, M. Douze, và C. Schmid, "Improving bag-of-features for large scale image search," vol. 87, no. 3, 2010, pp. 316–336.
- [33] J. Wan, D. Wang, S. C. H. Hoi, P. Wu, J. Zhu, Y. Zhang, và J. Li, "Deep learning for content-based image retrieval: A comprehensive study," trong *Proceedings of the 22nd ACM international conference on Multimedia*, 2014, pp. 157–166.
- [34] B. Cao, A. Araujo, và J. Sim, "Unifying deep local and global features for image search," trong *European Conference on Computer Vision*. Springer, 2020, pp. 726–743.
- [35] D. Varga và T. Sziranyi, "Fast content-based image retrieval using convolutional neural network and hash function," trong *2016 IEEE international conference on systems, man, and cybernetics (SMC)*. IEEE, 2016, pp. 002636–002640.
- [36] W.-L. Zhao, H. Jegou, và G. Gravier, "Oriented pooling for dense and non-dense rotation-invariant features," 2013.
- [37] S. A. Vassou, N. Anagnostopoulos, K. Christodoulou, A. Amanatiadis, và S. A. Chatzichristofis, "Como: a scale and rotation invariant compact composite moment-based descriptor for image retrieval," *Multimedia Tools and Applications*, pp. 1–24, 2018.
- [38] A. Sharif Razavian, H. Azizpour, J. Sullivan, và S. Carlsson, "Cnn features off-the-shelf: an astounding baseline for recognition," trong *Proceedings of the IEEE conference on computer vision and pattern recognition workshops*, 2014, pp. 806–813.
- [39] Y. Gong, L. Wang, R. Guo, và S. Lazebnik, "Multi-scale orderless pooling of deep convolutional activation features," trong *Computer Vision - ECCV 2014*, 2014, pp. 392–407.

- [40] M. Paulin, M. Douze, Z. Harchaoui, J. Mairal, F. Perronnin, và C. Schmid, "Local convolutional features with unsupervised training for image retrieval," trong *2015 IEEE International Conference on Computer Vision (ICCV 2015)*, 2015, pp. 91–99.
- [41] A. Babenko, A. Slesarev, A. Chigorin, và V. Lempitsky, "Neural codes for image retrieval," trong *European conference on computer vision*. Springer, 2014, pp. 584–599.
- [42] M. Paulin, M. Douze, Z. Harchaoui, J. Mairal, F. Perronnin, và C. Schmid, "Local convolutional features with unsupervised training for image retrieval," trong *Proceedings of the IEEE international conference on computer vision*, 2015, pp. 91–99.
- [43] C. Iakovidou, N. Anagnostopoulos, M. Lux, K. Christodoulou, Y. S. Boutalis, và S. A. Chatzichristofis, "Composite description based on salient contours and color information for CBIR tasks," *IEEE Trans. Image Processing*, vol. 28, no. 6, pp. 3115–3129, 2019.
- [44] P. Fischer, A. Dosovitskiy, và T. Brox, "Descriptor matching with convolutional neural networks: a comparison to sift," *arXiv preprint arXiv:1405.5769*, 2014.
- [45] S. A. Chatzichristofis và Y. S. Boutalis, "Cedd: Color and edge directivity descriptor: A compact descriptor for image indexing and retrieval," trong *ICVS*, 2008, pp. 312–322.
- [46] A. Gulli và S. Pal, *Deep learning with Keras*. Packt Publishing Ltd, 2017.